

Relatório Técnico — FIAP Tech Challenge (Fase 1)

Detecção de Risco em Câncer de Mama com Machine Learning

Autor: Thiago Ribeiro da Costa
RM: rm376167

Dataset: Kaggle (4.024 registros)
Stack: Python 3.12 | XGBoost | SHAP

Repositório:
github.com/trcosta97/fiap-id-tech-challenge1

1. Discussões da Análise Exploratória (EDA)

A análise exploratória avaliou 4.024 registros sem valores ausentes. Constatou-se forte desbalanceamento na variável-alvo Status, exigindo estratégias de balanceamento algorítmico.




Figura 1: Distribuição da variável-alvo (Alive: 84,7% vs. Dead: 15,3%).

A análise clínica indicou que pacientes com **Estrogen Status** e **Progesterone Status** positivos possuem mortalidade acentuadamente menor em razão da elegibilidade para terapias hormonais direcionadas.




Figura 2: Proporção de sobrevivência e óbito por status de receptores hormonais.

A análise de dispersão numérica revelou que os casos com desfecho Dead concentram tumores significativamente maiores e contagens mais altas de linfonodos positivos examinados.




Figura 3: Dispersão das variáveis numéricas estratificadas por desfecho clínico.

2. Estratégias de Pré-processamento e Prevenção de Data Leakage

Tratamento de Data Leakage: Remoção de Survival Months

A variável `Survival Months` denota o tempo de acompanhamento prospectivo até o encerramento do estudo. Como demonstrado na Figura 4, a separação temporal é extrema. Por ser um dado que não existe no momento do diagnóstico inicial, sua manutenção causaria *data leakage* severo e invalidaria a aplicabilidade prática do modelo.




Figura 4: Densidade e dispersão de Survival Months evidenciando a dependência temporal do desfecho.

Pipeline de Pré-processamento:

- **Variável-Alvo:** Binarização de Status (*Alive* = 0, *Dead* = 1).
- **Features Numéricas (4):** Padronização com `StandardScaler` (Age, Tumor Size, Regional Node Examined, Reginol Node Positive).
- **Features Categóricas (10):** Codificação via `OrdinalEncoder` (Race, Marital Status, T Stage, N Stage, 6th Stage, Differentiate, Grade, A Stage, Estrogen Status, Progesterone Status).
- **Split Estratificado 80/20:** Treino com 3.219 registros e Teste com 805 registros, mantendo 15,3% de casos Dead em ambas as partições (`random_state=42`).

3. Modelos Avaliados e Comparação de Desempenho

Foram treinados três modelos com compensação de desbalanceamento: **Regressão Logística** (`class_weight='balanced'`), **Random Forest** (`class_weight='balanced_subsample'`) e **XGBoost** (`scale_pos_weight = 5.53`).

Modelo	Acurácia	Precisão (Dead)	Recall (Dead)	F1-Score (Dead)	ROC-AUC	CV F1 (5-Fold)
Regressão Logística (Vencedora)	0,700	0,277	0,594	0,377	0,719	0,411 ± 0,018
Random Forest	0,826	0,384	0,228	0,286	0,697	0,332 ± 0,029
XGBoost	0,767	0,290	0,366	0,324	0,681	0,330 ± 0,028




Figura 5: Matrizes de Confusão e Curvas ROC dos três classificadores no conjunto de teste.

Por que a Regressão Logística superou os ensembles?

Em triagem médica oncológica, um Falso Negativo (classificar paciente de risco como Alive) tem custo crítico. Os modelos Random Forest e XGBoost foram seduzidos pela classe majoritária, gerando 95 e 80 falsos negativos respectivamente. A **Regressão Logística capturou 73 dos 123 óbitos (Recall de 59,4%)** e obteve a maior área sob a curva ROC (**0,719**).

4. Interpretação Clínica e Explicabilidade (SHAP & Coeficientes)

A análise combinada dos coeficientes do modelo linear e da importância via valores SHAP comprova coerência com a literatura oncológica estabelecida:




Figura 6: Coeficientes da Regressão Logística (log-odds).




Figura 7: Importância média das variáveis ([SHAP value]).

- **Fatores Protetores (log-odds negativo):** Estrogen Status (-0.86) e Progesterone Status (-0.60) atuam reduzindo substancialmente a probabilidade prevista de óbito.
- **Fatores Agravantes (log-odds positivo):** Grade (+0.44), N Stage (+0.43), T Stage (+0.41) e Regional Node Positive (+0.35) aumentam o risco clínico previsto.

5. Limitações e Próximos Passos

Limitações

- Recall de 59,4%: ~40% dos casos de óbito ainda não são capturados.
- Validação restrita a um único dataset público tabular.

Próximos Passos

- Oversampling sintético da classe minoritária (SMOTE / ADASYN).
- Calibração do limiar de decisão probabilístico (Threshold Tuning).
- Validação externa em prontuários eletrônicos reais.

Declaração ética: Solução desenvolvida exclusivamente para auxílio à triagem médica. A tomada de decisão clínica é prerrogativa exclusiva do médico.